Описание проекта: оценка рисков невозврата кредита

В вашем распоряжении данные клиентов банка «Скрудж», которые планируют взять кредит. Вам необходимо выяснить, что из имеющихся данных влияет на своевременное погашение кредита и каким именно образом.

Исследование поможет в создании модели кредитного скоринга — системы для оценки способности потенциального заёмщика погасить свой кредит.

По каждому клиенту есть информация о его семейном положении, образовании, доходе и другие данные. Вам предстоит подготовить данные к анализу и исследовать их, в процессе отвечая на вопросы.

Описание данных

- `children` — количество детей в семье;
- `days_employed` — сколько дней работает клиент;
- `dob_years` — возраст клиента;
- `education` — уровень образования клиента;
- `education_id` — идентификатор образования клиента;
- `family_status` — семейное положение клиента;
- `family_status_id` — идентификатор семейного положения клиента;
- `gender` — пол клиента;
- `income_type` — тип дохода клиента;
- `debt` — был ли у клиента когда-либо просрочен платёж по кредиту;
- `total_income` — ежемесячный доход;
- `purpose` — причина оформления кредита.

Цель работы

- В рамках проекта необходимо проанализировать данные клинетов банка Скрудж для лдальнейшего опредления характеритсик заёмщика, влияющих на своевременное погашение кредита. Это поможет в дальнейшем создать основу для модели кредитного скоринга — системы для оценки способности потенциального заёмщика погасить свой кредит.

План работы

- Первичный анализ данных и предобработка
  - загрузка и изучение структуры данных
  - проверка и устранение пропущенных значений
  - устраненние некорректных значений
  - устранение неявных дубликатов
- Создание дополнительных признаков
  - разделите клиентов по уровню дохода
  - разделение по возрастным группам
  - разделение по количеству детей
- Исследование влияюших факторов
  - Уровень дохода
    - Анализ влияния дохода на своевременное погашение кредита
  - Образование
    - Исследование связи между уровнем образования и вероятностью задолженности
  - Возраст
    - Анализ возрастных категорий и их связи с задолженностью по кредитам
  - Количество детей
    - влияние количества детей на риск задолженности
- Анализ данных
  - построение графиков и сводных таблиц для наглядной визуализации сравннеия должников и не должников
- Проверка исследовательских гипотез
  - У клиентов с детьми более высокий уровень финансовой ответственности и, следовательно, более низкий риск просрочек по кредиту.
  - Одинокие мужчины с низким доходом чаще оказываются должниками, чем семейные мужчины со средним доходом.
- Выводы
  - описание полученных результатов и итоговые выводы проведённого исследования

Датасет содержит данные, которые несут в себе информацию о клиентах банка Скрудж:

- ***демография***
  - возраст, семейное положение, количество детей
- ***финансновые показатели***
  - уровень дохода, тип занятости
- ***данные об образовании***
- ***цель кредита***
- ____информацию о своевременности возврата кредита____

Шаг 1. Откройте файл с данными и изучите общую информацию

1. Загрузите датасет.
2. Сделайте копию датасета.
3. Изучите типы данных и определите, соответствуют ли они содержимому.
4. Напишите вывод.

In [2]:
```
# Импортируйте библиотеки для работы
# с таблицами и графиками
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

In [3]:
```
# Загрузите датасет в переменную df_raw или другую по вашему выбору.
# Он доступен по адресу <https://code.s3.yandex.net/datasets/credit_scoring_eng.csv>
# а при работе на платформе по адресу /datasets/credit_scoring_eng.csv
df_raw=pd.read_csv('https://code.s3.yandex.net/datasets/credit_scoring_eng.csv')
```

In [4]:
```
# При помощи метода .copy() скопируйте датасет
# для работы с ним в переменную df или другую
df=df_raw.copy()
```

In [5]:
```
# Изучите общую информацию о датасете
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 21525 entries, 0 to 21524
Data columns (total 12 columns):
 #   Column            Non-Null Count  Dtype  
---  ------            --------------  -----  
 0   children          21525 non-null  int64  
 1   days_employed     19351 non-null  float64
 2   dob_years         21525 non-null  int64  
 3   education         21525 non-null  object 
 4   education_id      21525 non-null  int64  
 5   family_status     21525 non-null  object 
 6   family_status_id  21525 non-null  int64  
 7   gender            21525 non-null  object 
 8   income_type       21525 non-null  object 
 9   debt              21525 non-null  int64  
 10  total_income      19351 non-null  float64
 11  purpose           21525 non-null  object 
dtypes: float64(2), int64(5), object(5)
memory usage: 2.0+ MB
```

In [6]:
```
df.head()
```

Out[6]:

	children	days_employed	dob_years	education	education_id	family_status	family_status_id	gender	income_type	debt	total_income	purpose
0	1	-8437.673028	42	bachelor's degree	0	married	0	F	employee	0	40620.102	purchase of the house
1	1	-4024.803754	36	secondary education	1	married	0	F	employee	0	17932.802	car purchase
2	0	-5623.422610	33	Secondary Education	1	married	0	M	employee	0	23341.752	purchase of the house
3	3	-4124.747207	32	secondary education	1	married	0	M	employee	0	42820.568	supplementary education
4	0	340266.072047	53	secondary education	1	civil partnership	1	F	retiree	0	25378.572	to have a wedding

1. Таблица представлена 12 колонками и 21525 строками

2. Данные в таблице представлены 3 типами: float64, int64 и object:

- int64 для столблцов *children, dob_years, education_id, family_status_id, u debt*
  - это целочисленные данные, что логично соответвует как описанию данных, так и простмору первых 5 строк таблицы
- float64 для столбцов *days_employed u total_income*
  - это числовые данные с плавающей точкой, что логично соответвует описанию данных, так и простмору первых 5 строк таблицы
- object для столбцов *education, family_status, gender, income_type, u purpose*
  - это текстовые данные , что логично соответвует описанию данных, так и простмору первых 5 строк таблицы

3. Также стоит обратить внимани на колонки days_employed и total_income.

- В обоих колонках количество строк (19351) не соответствует общему количеству строк таблицы(21525)
  - таким образом в этих стоблцах могут быть пропцщенные значения, например NAN

Шаг 2. Выполните предобработку данных

1. Найдите и изучите пропущенные значения в столбцах.
2. Устраните пропущенные значения: удалите или замените их.
3. Объясните выбранную стратегию обработки пропущенных значений.

In [7]:
```
# найдем пропущенные значения в общем количестве
df.isnull().sum().sort_values(ascending=False)
```

Out[7]:
```
days_employed       2174
total_income        2174
children               0
dob_years              0
education              0
education_id           0
family_status          0
family_status_id       0
gender                 0
income_type            0
debt                   0
purpose                0
dtype: int64
```

In [9]:
```
# найдем пропущенные значения в процентном соотношении
df.isnull().mean().sort_values(ascending=False)
```

Out[9]:
```
days_employed       0.100999
total_income        0.100999
children            0.000000
dob_years           0.000000
education           0.000000
education_id        0.000000
family_status       0.000000
family_status_id    0.000000
gender              0.000000
income_type         0.000000
debt                0.000000
purpose             0.000000
dtype: float64
```

- в колонках *days_employed и total_income* 2174 пропусков, что составляет 10 процентов от всех данных
- слишком большой процент для удаления строк из данных
- поэтому было решено заменить пропуски в зависимости от типа данных

сначада для обоих столбцов применим describe()

In [10]:
```
# Применение метода describe() к двум столбцам: 'days_employed' и 'total_income'
df[['days_employed', 'total_income']].describe()
```

Out[10]:

	days_employed	total_income
count	19351.000000	19351.000000
mean	63046.497661	26787.568355
std	140827.311974	16475.450632
min	-18388.949901	3306.762000
25%	-2747.423625	16488.504500
50%	-1203.369529	23202.870000
75%	-291.095954	32549.611000
max	401755.400475	362496.645000

в колонке days_employed присуствуют отрицательные значения(это приславутые аномалии)

- пропущенные же знаенчия заменим 0
  - из идеи что клиенты могли быть безработными на момент заполения данных

In [11]:
```
# Замена пропущенных значений в days_employed на 0
df['days_employed'].fillna(0, inplace=True)
```

в колонке total_income обратим внимание на мин макс значения

- то есть присуствуют явные выбросы
  - таким образом выбираем для замены медианное значение, поскольку оно менее чувствительно ким

In [12]:
```
# Замена пропущенных значений в total_income на медианное значение
df['total_income'].fillna(df['total_income'].median(), inplace=True)
```

еще раз проверим данные на пропуски

In [14]:
```
# найдем пропущенные значения в общем количестве
df.isnull().sum().sort_values(ascending=False)
```

Out[14]:
```
children            0
days_employed       0
dob_years           0
education           0
education_id        0
family_status       0
family_status_id    0
gender              0
income_type         0
debt                0
total_income        0
purpose             0
dtype: int64
```

1. Изучите уникальные значения в столбцах с уровнем образования (`education`) и полом клиента (`gender`).
2. Устраните неявные дубликаты и некорректные значения.

In [17]:
```
# Уникальные значения в столбце education
df['education'].unique()
```

Out[17]:
```
array(["bachelor's degree", 'secondary education', 'Secondary Education',
       'SECONDARY EDUCATION', "BACHELOR'S DEGREE", 'some college',
       'primary education', "Bachelor's Degree", 'SOME COLLEGE',
       'Some College', 'PRIMARY EDUCATION', 'Primary Education',
       'Graduate Degree', 'GRADUATE DEGREE', 'graduate degree'],
      dtype=object)
```

In [19]:
```
sorted(df['education'].unique())
```

Out[19]:
```
["BACHELOR'S DEGREE",
 "Bachelor's Degree",
 'GRADUATE DEGREE',
 'Graduate Degree',
 'PRIMARY EDUCATION',
 'Primary Education',
 'SECONDARY EDUCATION',
 'SOME COLLEGE',
 'Secondary Education',
 'Some College',
 "bachelor's degree",
 'graduate degree',
 'primary education',
 'secondary education',
 'some college']
```

- при анализе уникальных значений в колонке education видны повторяющиеся текстовые значения по смысловому содержанию, но в разных стилях написания
  - например'Secondary Education'и 'SECONDARY EDUCATION'
  - нужно привести все в нижний регистр

In [20]:
```
# Уникальные значения в столбце education
df['gender'].unique()
```

Out[20]:
```
array(['F', 'M', 'XNA'], dtype=object)
```

- при анализе уникальных значений в колонке gender видны XNA
  - заменим на 'Unknown'

проведем замену и перепроверим уникальные значения в стоблцах education и gender

In [21]:
```
# Приведение всех значений в столбце education к нижнему регистру для устранения дубликатов
df['education'] = df['education'].str.lower()
```

In [22]:
```
# Уникальные значения в столбце education
df['education'].unique()
```

Out[22]:
```
array(["bachelor's degree", 'secondary education', 'some college',
       'primary education', 'graduate degree'], dtype=object)
```

In [23]:
```
sorted(df['education'].unique())
```

Out[23]:
```
["bachelor's degree",
 'graduate degree',
 'primary education',
 'secondary education',
 'some college']
```

In [117…
```
# Устранение некорректных значений в столбце gender
df['gender'] = df['gender'].replace({'XNA': 'Unknown'})
```

In [118…
```
# Уникальные значения в столбце education
df['gender'].unique()
```

Out[118… array(['F', 'M', 'Unknown'], dtype=object)

проверем информацию по исходной таблице и таблице на данном этапе анализа

In [119…
```
df_raw.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 21525 entries, 0 to 21524
Data columns (total 12 columns):
 #   Column            Non-Null Count  Dtype  
---  ------            --------------  -----  
 0   children          21525 non-null  int64  
 1   days_employed     19351 non-null  float64
 2   dob_years         21525 non-null  int64  
 3   education         21525 non-null  object 
 4   education_id      21525 non-null  int64  
 5   family_status     21525 non-null  object 
 6   family_status_id  21525 non-null  int64  
 7   gender            21525 non-null  object 
 8   income_type       21525 non-null  object 
 9   debt              21525 non-null  int64  
 10  total_income      19351 non-null  float64
 11  purpose           21525 non-null  object 
dtypes: float64(2), int64(5), object(5)
memory usage: 2.0+ MB
```

In [120…
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 21525 entries, 0 to 21524
Data columns (total 12 columns):
 #   Column            Non-Null Count  Dtype  
---  ------            --------------  -----  
 0   children          21525 non-null  int64  
 1   days_employed     21525 non-null  float64
 2   dob_years         21525 non-null  int64  
 3   education         21525 non-null  object 
 4   education_id      21525 non-null  int64  
 5   family_status     21525 non-null  object 
 6   family_status_id  21525 non-null  int64  
 7   gender            21525 non-null  object 
 8   income_type       21525 non-null  object 
 9   debt              21525 non-null  int64  
 10  total_income      21525 non-null  float64
 11  purpose           21525 non-null  object 
dtypes: float64(2), int64(5), object(5)
memory usage: 2.0+ MB
```

1. Проверьте наличие дубликатов. Изучите дублированные данные, если они есть, и примите решение — удалять их или оставить.

In [121…
```
# Проверка наличия дубликатов
duplicates = df.duplicated()
print(f'Количество дубликатов: {duplicates.sum()}')
```

```
Количество дубликатов: 71
```

- в данных присусвует 71 дубликат
- выведим пример дубликатов

In [122…
```
# Изучение дублированных данных
duplicate_rows = df[df.duplicated()]
duplicate_rows.head()
```

Out[122…

	children	days_employed	dob_years	education	education_id	family_status	family_status_id	gender	income_type	debt	total_income	purpose
2849	0	0.0	41	secondary education	1	married	0	F	employee	0	23202.87	purchase of the house for my family
3290	0	0.0	58	secondary education	1	civil partnership	1	F	retiree	0	23202.87	to have a wedding
4182	1	0.0	34	bachelor's degree	0	civil partnership	1	F	employee	0	23202.87	wedding ceremony
4851	0	0.0	60	secondary education	1	civil partnership	1	F	retiree	0	23202.87	wedding ceremony
5557	0	0.0	58	secondary education	1	civil partnership	1	F	retiree	0	23202.87	to have a wedding

- на первый взгляд сложно оценить какие именно строки дублируются
- для лучшей визуализации отсортируем дублированные строки

In [123…
```
# Найти и отсортировать дублированные строки
duplicate_rows = df[df.duplicated(keep=False)]
```

```
sorted_duplicates = duplicate_rows.sort_values(by=list(df.columns))

sorted_duplicates.head(6)
```

Out[123…

	children	days_employed	dob_years	education	education_id	family_status	family_status_id	gender	income_type	debt	total_income	purpos
15892	0	0.0	23	secondary education	1	unmarried	4	F	employee	0	23202.87	second hand ca purchas
19321	0	0.0	23	secondary education	1	unmarried	4	F	employee	0	23202.87	second hand ca purchas
3452	0	0.0	29	bachelor's degree	0	married	0	M	employee	0	23202.87	bu residentia rea estat
18328	0	0.0	29	bachelor's degree	0	married	0	M	employee	0	23202.87	bu residentia rea estat
4216	0	0.0	30	secondary education	1	married	0	M	employee	0	23202.87	building rea estat
6312	0	0.0	30	secondary education	1	married	0	M	employee	0	23202.87	building rea estat

- удлаим дубликаты

In [124…
```
# Удаление дубликатов
df = df.drop_duplicates()
print(f'Количество дубликатов после удаления: {df.duplicated().sum()}')
```

```
Количество дубликатов после удаления: 0
```

проверем информацию по исходной таблице и таблице на данном этапе анализа

In [125…
```
df_raw.shape
```

Out[125… (21525, 12)

In [126…
```
df.shape
```

Out[126… (21454, 12)

In [127…
```
#строк стало на 71 меньше
print(f'Количество строк стало меньше на : {round((1-df.shape[0]/df_raw.shape[0])*100,2)} процента')
```

```
Количество строк стало меньше на : 0.33 процента
```

Шаг 3. Выбросы и аномальные значения

Изучите столбцы `total_income` , `dob_age` , `chidlren` на наличие выбросов и аномальных значений, в том числе при помощи графиков. Если выбросы или аномалии будут обнаружены — обоснованно примите решение об их судьбе. Используйте подзаголовки третьего уровня (`###` `Подзаголовок`), чтобы создать структуру действий в рамках этого шага.

Проанализмруем столбцы total_income, dob_years и children методом describe()

In [128…
```
display(df[['total_income', 'dob_years', 'children']].describe())
```

	total_income	dob_years	children
count	21454.000000	21454.000000	21454.000000
mean	26436.183035	43.271231	0.539946
std	15683.361605	12.570822	1.383444
min	3306.762000	0.000000	-1.000000
25%	17219.817250	33.000000	0.000000
50%	23202.870000	42.000000	0.000000
75%	31330.237250	53.000000	1.000000
max	362496.645000	75.000000	20.000000

- **total_income**:
  - минимальное значение 3306.76 и максимальное значение 362496.65(значительно превышает 75-й процентиль (31330.24)) указывают на наличие выбросов, соответственно можно заменить экстремальные значения на медиану или удалить

    - среднее значени выше медианного
- **dob_years**:
    - максимум 75 лет в пределах разумного, но возраст 0 явно аномалия.
    - среднее значени близко к медианнму, что о говорит о возможной симметричности в распределении
- **children**:
    - присуствуюя явные аномальные значения -1 и 20, соответственно можно заменить их на медиану или удалить.

Построим граифки для столбцов total_income, dob_years и children

- используем для анализа аномалий и выборосов график boxplot и распределение на основе гистограммы

In [129…
```
import matplotlib.pyplot as plt
import seaborn as sns

# Построение графика для `total_income`
plt.figure(figsize=(8, 5))
sns.boxplot(x=df['total_income'])
plt.title('Boxplot для total_income')
plt.show()
```

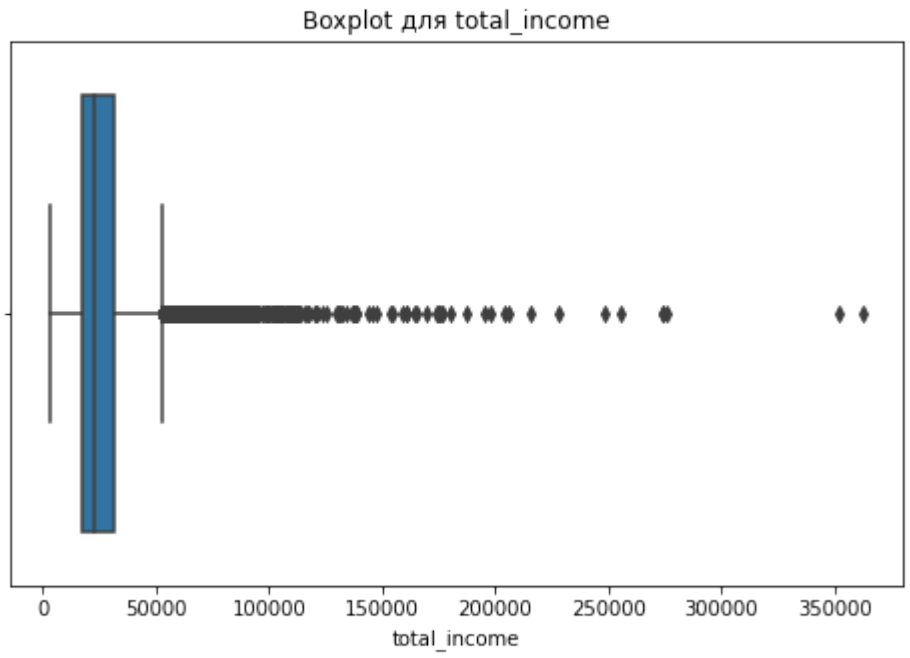

In [130…
```
plt.figure(figsize=(8,5))
sns.histplot(df['total_income'], bins=30, kde=True)
plt.title('Гистограмма для total_income')
plt.show()
```

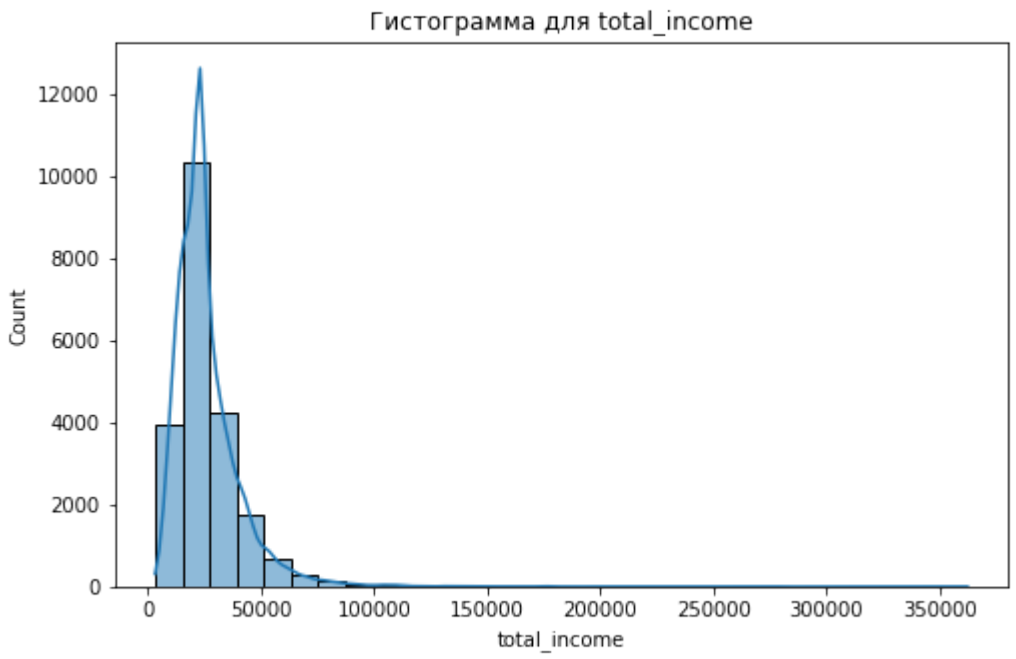

In [131…
```
Q1 = df['total_income'].quantile(0.25)
Q3 = df['total_income'].quantile(0.75)
IQR=Q3-Q1
print(f'Нижняя граница : {Q1 - 1.5*IQR }')
print(f'Верхняя граница : {Q3 + 1.5*IQR }')
```

```
Нижняя граница : -3945.8127499999973
Верхняя граница : 52495.867249999996
```

- на графике видно, что есть значительное количество выбросов справа по данным в столбце total_income.
- есть значения, выходящие за верхний предел, что может указывать на аномалии.

In [132…
```
# Построение графика для `dob_years`
plt.figure(figsize=(8, 5))
sns.boxplot(x=df['dob_years'])
plt.title('Boxplot для dob_years')
plt.show()
```

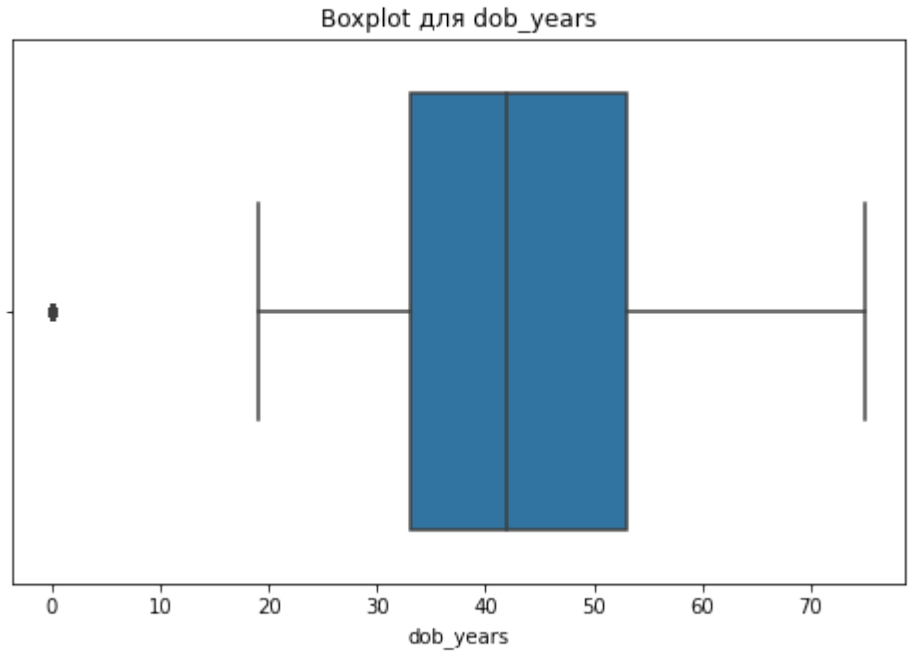

In [133…
```
plt.figure(figsize=(8, 5))
sns.histplot(df['dob_years'], bins=30, kde=True)
plt.title('Гистограмма для dob_years')
plt.show()
```

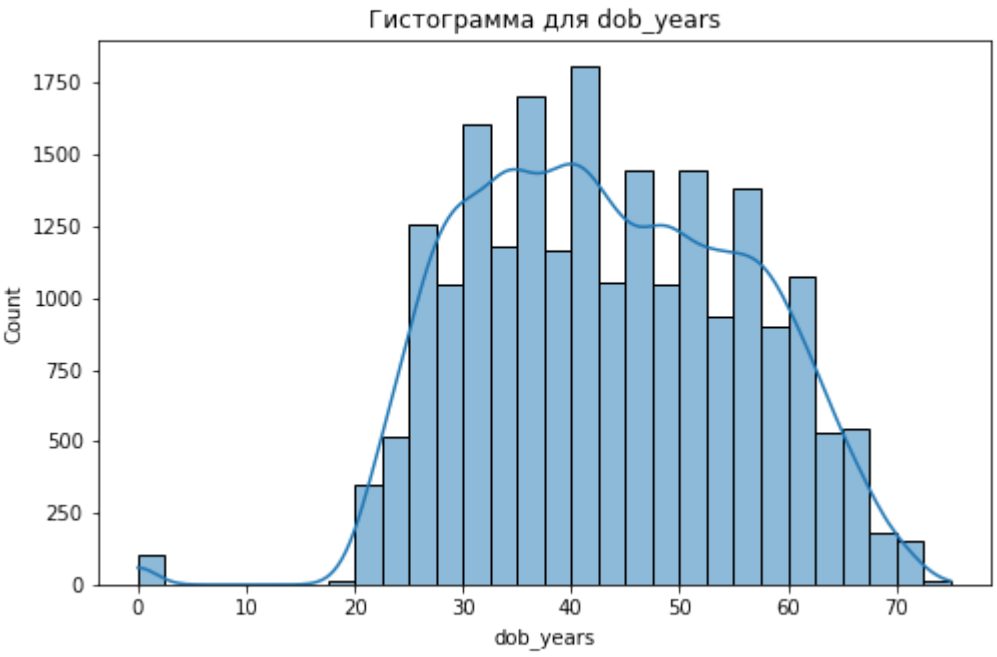

In [134…
```
Q1 = df['dob_years'].quantile(0.25)
Q3 = df['dob_years'].quantile(0.75)
IQR=Q3-Q1
print(f'Нижняя граница : {Q1 - 1.5*IQR }')
print(f'Верхняя граница : {Q3 + 1.5*IQR }')
```

```
Нижняя граница : 3.0
Верхняя граница : 83.0
```

- на графике видны выбросы сдева
- возраст 0 явно является явной аномалией, так как клтент не может быть младше 18 лет

In [135…
```
# Построение графика для `children`
plt.figure(figsize=(8, 5))
sns.boxplot(x=df['children'])
plt.title('Boxplot для children')
plt.show()
```

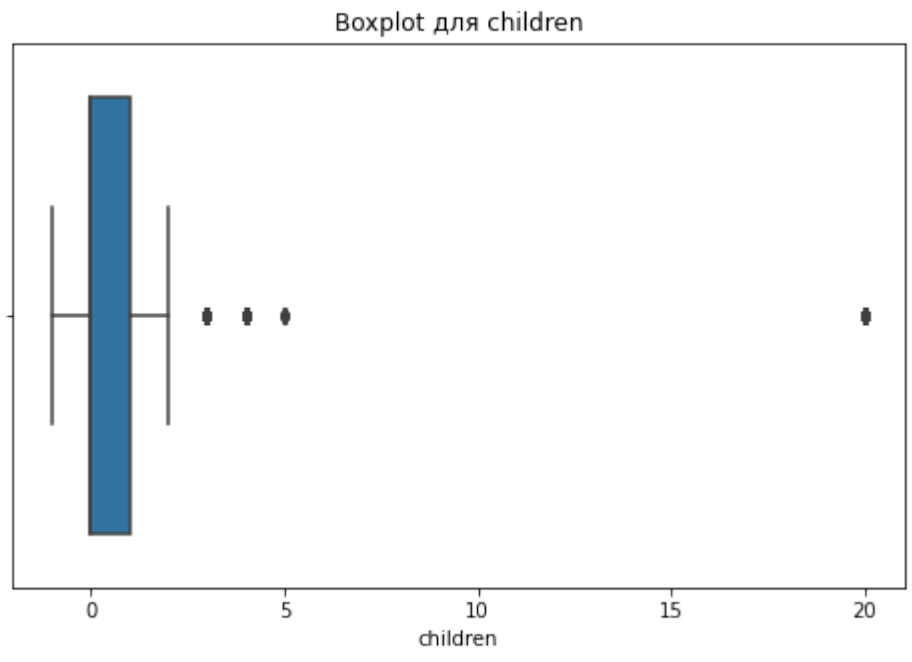

In [136…
```
plt.figure(figsize=(8, 5))
sns.histplot(df['children'], bins=30, kde=True)
plt.title('Гистограмма для children')
plt.show()
```

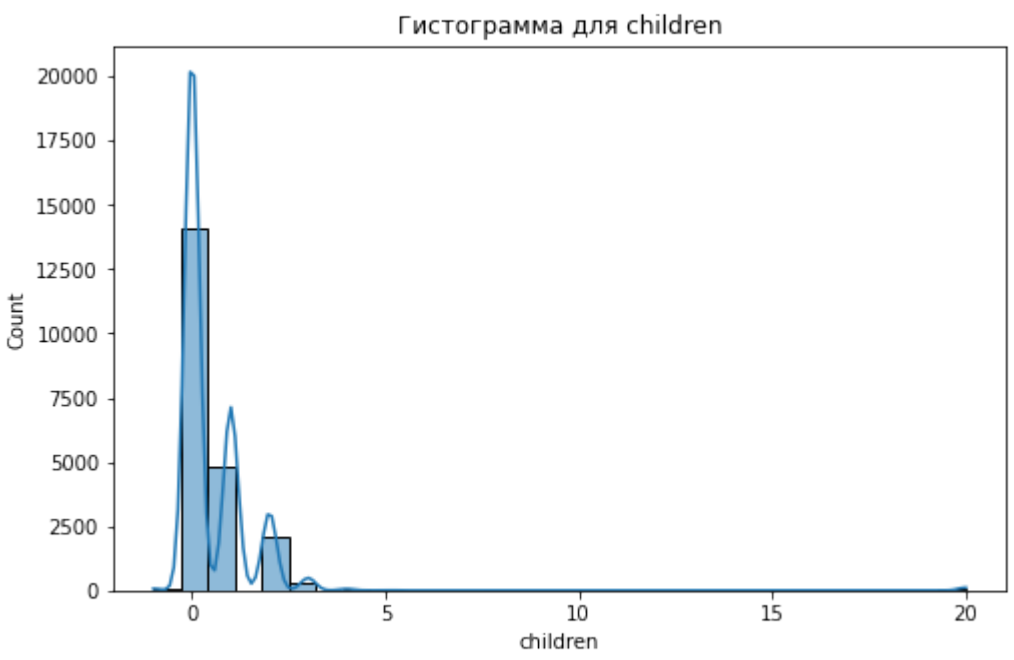

- видно несколько выбросов справа (большое количество детей 20)
- на графике видно, что есть аномальные значени -1

Решение по выбросам

- для колонки total_income(ежемесячный доход)
  - лучше удалить выбросы,чтоб они не искажади данные.

In [137…
```
upper_limit = df['total_income'].quantile(0.95)  # определение верхнего предела выбросов
df = df[df['total_income'] <= upper_limit]
```

In [138…
```
df['total_income'].describe()
```

Out[138…
```
count    20381.000000
mean     24007.680143
std       9821.324564
min       3306.762000
25%      16823.508000
50%      23202.870000
75%      29411.892000
max      53039.263000
Name: total_income, dtype: float64
```

- для колонки dob_years(возраст клиента)
  - посмтотрим количсетво 0

In [139…
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 20381 entries, 0 to 21524
Data columns (total 12 columns):
 #   Column            Non-Null Count  Dtype
---  ------            --------------  -----
 0   children          20381 non-null  int64
 1   days_employed     20381 non-null  float64
 2   dob_years         20381 non-null  int64
 3   education         20381 non-null  object
 4   education_id      20381 non-null  int64
 5   family_status     20381 non-null  object
 6   family_status_id  20381 non-null  int64
 7   gender            20381 non-null  object
 8   income_type       20381 non-null  object
 9   debt              20381 non-null  int64
 10  total_income      20381 non-null  float64
 11  purpose           20381 non-null  object
dtypes: float64(2), int64(5), object(5)
memory usage: 2.0+ MB
```

In [140…
```
df[df['dob_years'] == 0].shape[0]
```

Out[140…
```
100
```

- удалим 0

In [141…
```
# Удалить строки, где dob_years равен 0
df = df[df['dob_years'] != 0]
```

In [142…
```
df['dob_years'].describe()
```

Out[142…
```
count    20281.000000
mean        43.514274
std         12.323288
min         19.000000
25%         33.000000
50%         43.000000
75%         53.000000
max         75.000000
Name: dob_years, dtype: float64
```

- для колонки children(количество детей в семье)
  - посмтотрим количсетво -1 и 20

In [143…
```
df[df['children'] == -1].shape[0]
```

Out[143…
```
47
```

In [144…
```
df[df['children'] == 20].shape[0]
```

Out[144…
```
73
```

- удалим -1 и 20

In [145…
```
# Удалить строки, где children равен -1
df = df[df['children'] != -1]
```

In [146…
```
# Удалить строки, где children равен 20
df = df[df['children'] != 20]
```

In [147…
```
df['children'].describe()
```

Out[147…
```
count    20161.000000
mean         0.470612
std          0.749234
min          0.000000
25%          0.000000
50%          0.000000
75%          1.000000
max          5.000000
Name: children, dtype: float64
```

воспользуемся еще раз describe для демонстрации статистики по столбцам и отсутствию выбросов

In [148…
```
display(df[['total_income', 'dob_years', 'children']].describe())
```

	total_income	dob_years	children
count	20161.000000	20161.000000	20161.000000
mean	23997.798351	43.519865	0.470612
std	9812.385382	12.329629	0.749234
min	3306.762000	19.000000	0.000000
25%	16817.222000	33.000000	0.000000
50%	23202.870000	43.000000	0.000000
75%	29410.209000	54.000000	1.000000
max	53039.263000	75.000000	5.000000

также продулируем построение графиков для визуализации данных

In [149…
```
import matplotlib.pyplot as plt
import seaborn as sns

# Построение графика для `total_income`
plt.figure(figsize=(8, 5))
sns.boxplot(x=df['total_income'])
plt.title('Boxplot для total_income')
plt.show()
```

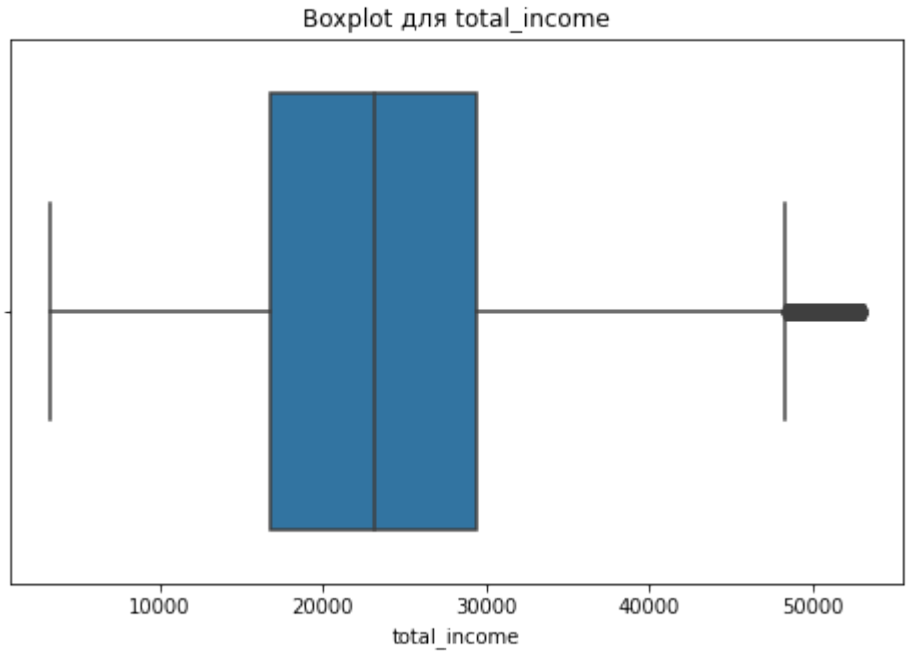

In [150…
```
# Построение графика для `dob_years`
plt.figure(figsize=(8, 5))
sns.boxplot(x=df['dob_years'])
plt.title('Boxplot для dob_years')
plt.show()
```

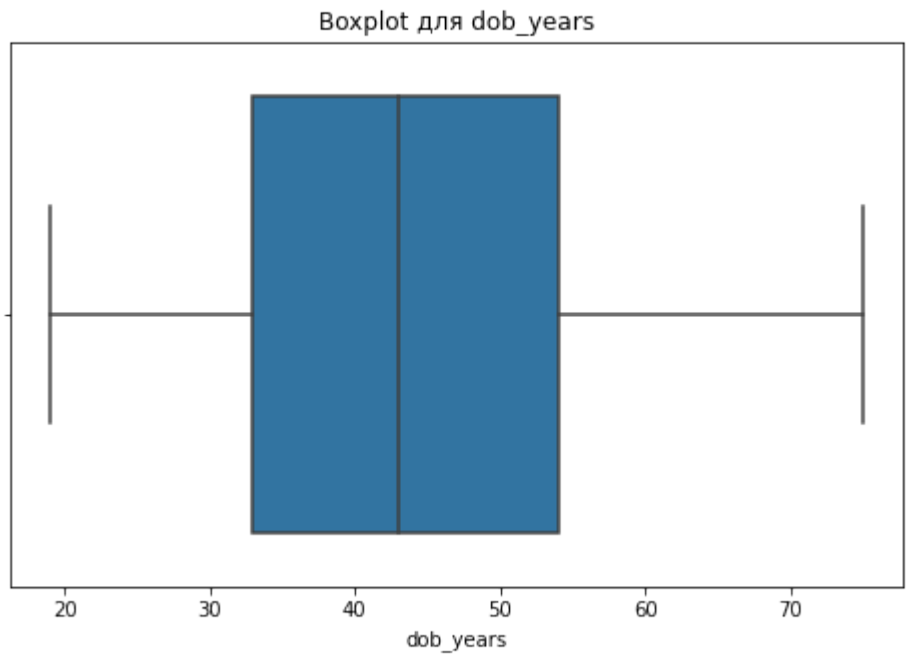

In [151…
```
# Построение графика для `children`
plt.figure(figsize=(8, 5))
sns.boxplot(x=df['children'])
plt.title('Boxplot для children')
plt.show()
```

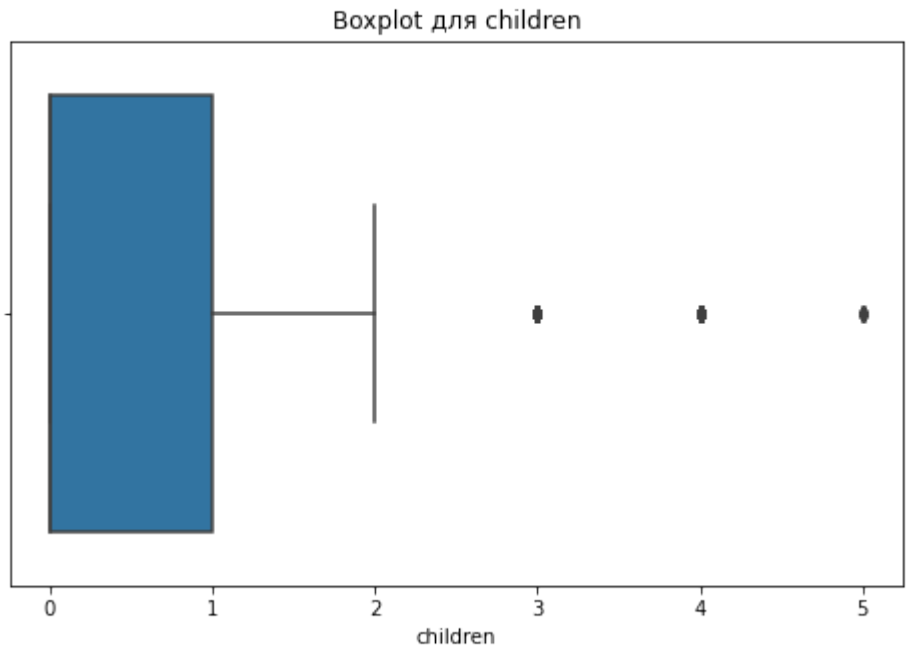

проверем информацию по исходной таблице и таблице на данном этапе анализа

In [152…
```
df_raw.shape
```

Out[152…
```
(21525, 12)
```

In [153…
```
df.shape
```

Out[153…
```
(20161, 12)
```

In [154…
```
#строк стало на 71 меньше
print(f'Количество строк стало меньше на : {round((1-df.shape[0]/df_raw.shape[0])*100,2)} процента')
```

```
Количество строк стало меньше на : 6.34 процента
```

Шаг 4. Добавьте в таблицу новые столбцы

1. **Разделите клиентов на 5 категорий по уровню дохода:**

- Без дохода — люди без работы и с нулевым доходом.
- Очень низкий доход — люди, получающие ниже 14 процентиля от общего распределения дохода.
- Низкий доход — люди, получающие между 14 и 34 процентилями от общего распределения дохода.
- Средний доход — люди, получающие между 34 и 78 процентилями от общего распределения дохода.
- Высокий доход — люди, получающие больше 78 процентиля от общего распределения дохода.

In [155…

```python
# Процентильные границы
percentile_14 = df['total_income'].quantile(0.14)
percentile_34 = df['total_income'].quantile(0.34)
percentile_78 = df['total_income'].quantile(0.78)

# Функция для присвоения категорий
def income_category(income):
    if income == 0:
        return 'Без дохода'
    elif income < percentile_14:
        return 'Очень низкий доход'
    elif income < percentile_34:
        return 'Низкий доход'
    elif income < percentile_78:
        return 'Средний доход'
    else:
        return 'Высокий доход'

# Создание новой колонки согласно функции
df['income_category'] = df['total_income'].apply(income_category)

display(df[['total_income', 'income_category']].head())
print(df['income_category'].value_counts())
```

	total_income	income_category
0	40620.102	Высокий доход
1	17932.802	Низкий доход
2	23341.752	Средний доход
3	42820.568	Высокий доход
4	25378.572	Средний доход

```
Средний доход          8870
Высокий доход          4436
Низкий доход           4032
Очень низкий доход     2823
Name: income_category, dtype: int64
```

1. Разделите клиентов на две категории по возрасту: до 40 лет и после. Сохраните результат в колонке `age_category`.

In [156…

```python
# Место для вашего кода
# Функция для присвоения возрастных категорий
def age_category(age):
    if age < 40:
        return 'до 40 лет'
    else:
        return 'после 40 лет'
df['age_category'] = df['dob_years'].apply(age_category)
display(df[['dob_years', 'age_category']].head())
```

	dob_years	age_category
0	42	после 40 лет
1	36	до 40 лет
2	33	до 40 лет
3	32	до 40 лет
4	53	после 40 лет

1. Разделите клиентов на несколько категорий по количеству детей: без детей, от одного до двух, от трёх и больше. Сохраните результат в колонке `childrens_category`.

In [157…

```python
# Место для вашего кода
def childrens_category(children):
    if children == 0:
        return 'без детей'
    elif children <= 2:
```

```
        return 'от одного до двух'
    else:
        return 'от трёх и больше'
df['childrens_category'] = df['children'].apply(childrens_category)
display(df[['children','childrens_category']].head())
```

	children	childrens_category
0	1	от одного до двух
1	1	от одного до двух
2	0	без детей
3	3	от трёх и больше
4	0	без детей

как итог

In [158…
```
display(df[['children','childrens_category','dob_years', 'age_category','total_income','income_category']].head(10))
```

	children	childrens_category	dob_years	age_category	total_income	income_category
0	1	от одного до двух	42	после 40 лет	40620.102	Высокий доход
1	1	от одного до двух	36	до 40 лет	17932.802	Низкий доход
2	0	без детей	33	до 40 лет	23341.752	Средний доход
3	3	от трёх и больше	32	до 40 лет	42820.568	Высокий доход
4	0	без детей	53	после 40 лет	25378.572	Средний доход
5	0	без детей	27	до 40 лет	40922.170	Высокий доход
6	0	без детей	43	после 40 лет	38484.156	Высокий доход
7	0	без детей	50	после 40 лет	21731.829	Средний доход
8	2	от одного до двух	35	до 40 лет	15337.093	Низкий доход
9	0	без детей	41	после 40 лет	23108.150	Средний доход

Шаг 5. Проведите исследовательский анализ данных

Задайте структуру наиболее объёмной части исследования. Исследуйте факторы: `Уровень дохода`, `Образование`, `Возраст`, `Количество детей`. Отличается ли распределение между должниками и нет? Исследуйте вопрос графически. Постройте сводную таблицу по каждому фактору и покажите, как часто встречаются должники в каждой группе клиентов. Выберите подходящую визуализацию и сравните 2 группы.

- визуализируем таблицу с колонками, данные из которых будем анализировать

In [159…
```
display(df[['income_category', 'education', 'dob_years', 'age_category', 'children', 'childrens_category', 'debt','total_income']].head(10)
```

	income_category	education	dob_years	age_category	children	childrens_category	debt	total_income
0	Высокий доход	bachelor's degree	42	после 40 лет	1	от одного до двух	0	40620.102
1	Низкий доход	secondary education	36	до 40 лет	1	от одного до двух	0	17932.802
2	Средний доход	secondary education	33	до 40 лет	0	без детей	0	23341.752
3	Высокий доход	secondary education	32	до 40 лет	3	от трёх и больше	0	42820.568
4	Средний доход	secondary education	53	после 40 лет	0	без детей	0	25378.572
5	Высокий доход	bachelor's degree	27	до 40 лет	0	без детей	0	40922.170
6	Высокий доход	bachelor's degree	43	после 40 лет	0	без детей	0	38484.156
7	Средний доход	secondary education	50	после 40 лет	0	без детей	0	21731.829
8	Низкий доход	bachelor's degree	35	до 40 лет	2	от одного до двух	0	15337.093
9	Средний доход	secondary education	41	после 40 лет	0	без детей	0	23108.150

- **Уровень дохода**

In [160…
```
# Место для вашего кода
income_pivot = df.pivot_table(index='income_category', columns='debt', values='total_income', aggfunc='count')
display(income_pivot)
income_pivot.plot(kind='bar', figsize=(10, 6))
plt.title('Распределение должников и недолжников по уровню дохода')
plt.xlabel('Категория дохода')
plt.ylabel('Количество')
plt.legend(['Недолжники', 'Должники'])
```

debt	0	1
income_category		
Высокий доход	4115	321
Низкий доход	3691	341
Очень низкий доход	2608	215
Средний доход	8098	772

Out[160… <matplotlib.legend.Legend at 0x7fbabec72d30>

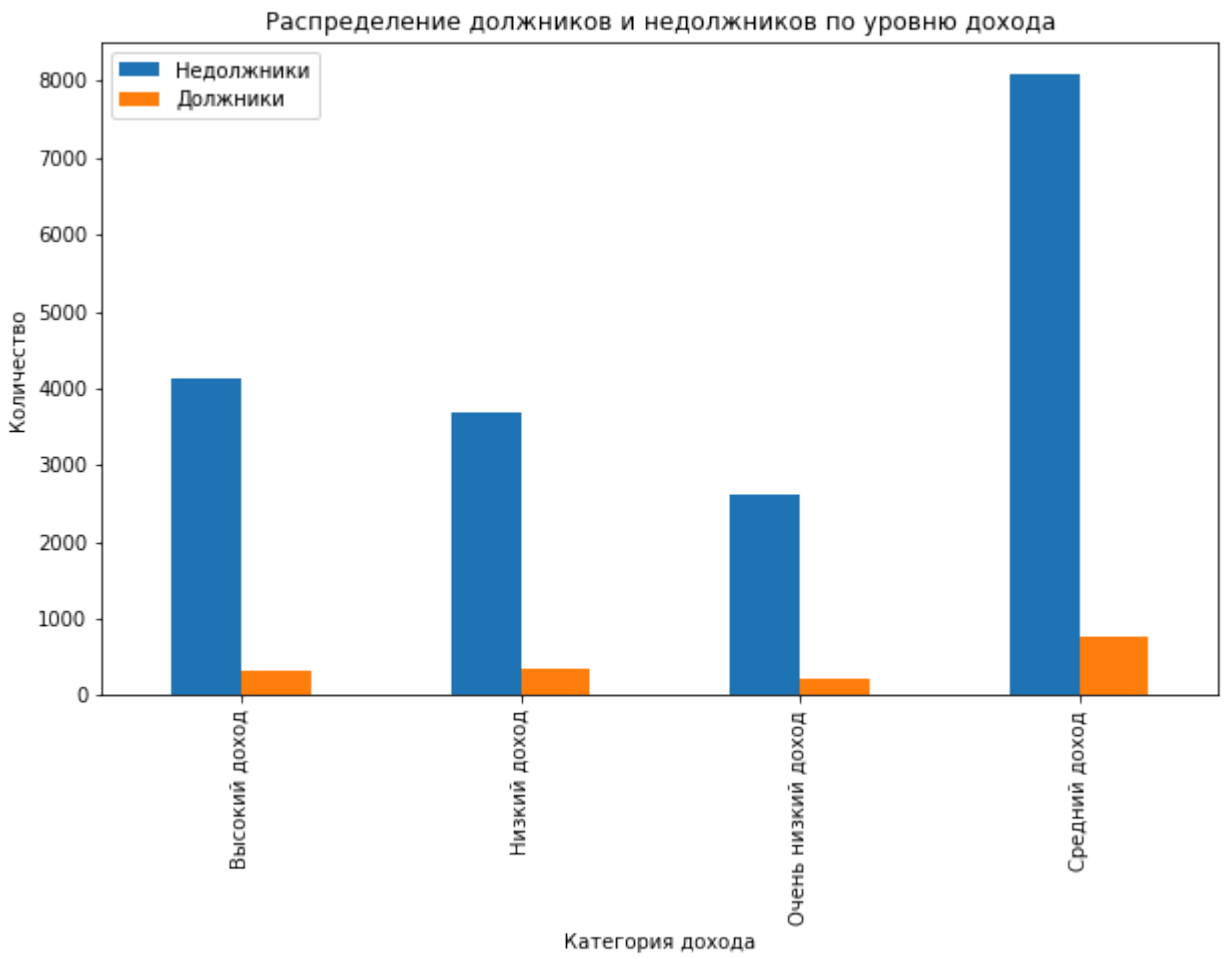

- **Образование**

In [161…
```
education_pivot = df.pivot_table(index='education', columns='debt', values='total_income', aggfunc='count')
display(education_pivot)
education_pivot.plot(kind='bar', figsize=(10, 6))
plt.title('Распределение должников и недолжников по уровню образования')
plt.xlabel('Уровень образования')
plt.ylabel('Количество')
plt.legend(['Недолжники', 'Должники'])
```

debt	0	1
education		
bachelor's degree	4377.0	254.0
graduate degree	6.0	NaN
primary education	248.0	31.0
secondary education	13240.0	1303.0
some college	641.0	61.0

Out[161… <matplotlib.legend.Legend at 0x7fbabe959100>

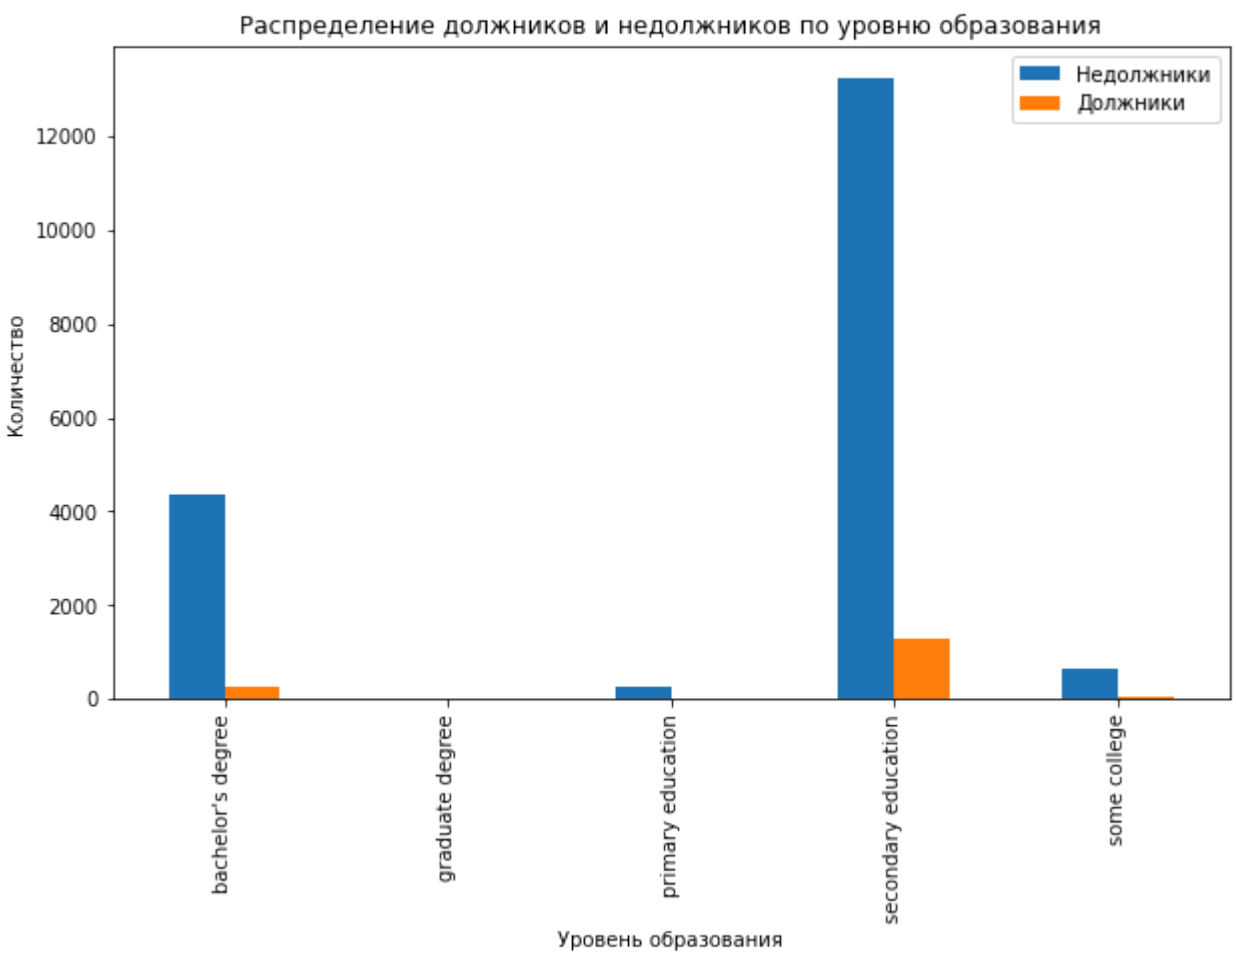

- **Возраст**

In [162…
```
age_pivot = df.pivot_table(index='age_category', columns='debt', values='dob_years', aggfunc='count')
display(age_pivot)
age_pivot.plot(kind='bar', figsize=(10, 6))
plt.title('Распределение должников и недолжников по возрасту')
plt.xlabel('Возрастная категория')
plt.ylabel('Количество')
plt.legend(['Недолжники', 'Должники'])
```

debt	0	1
age_category		
до 40 лет	7493	861
после 40 лет	11019	788

Out[162…
```
<matplotlib.legend.Legend at 0x7fbabeaf4550>
```

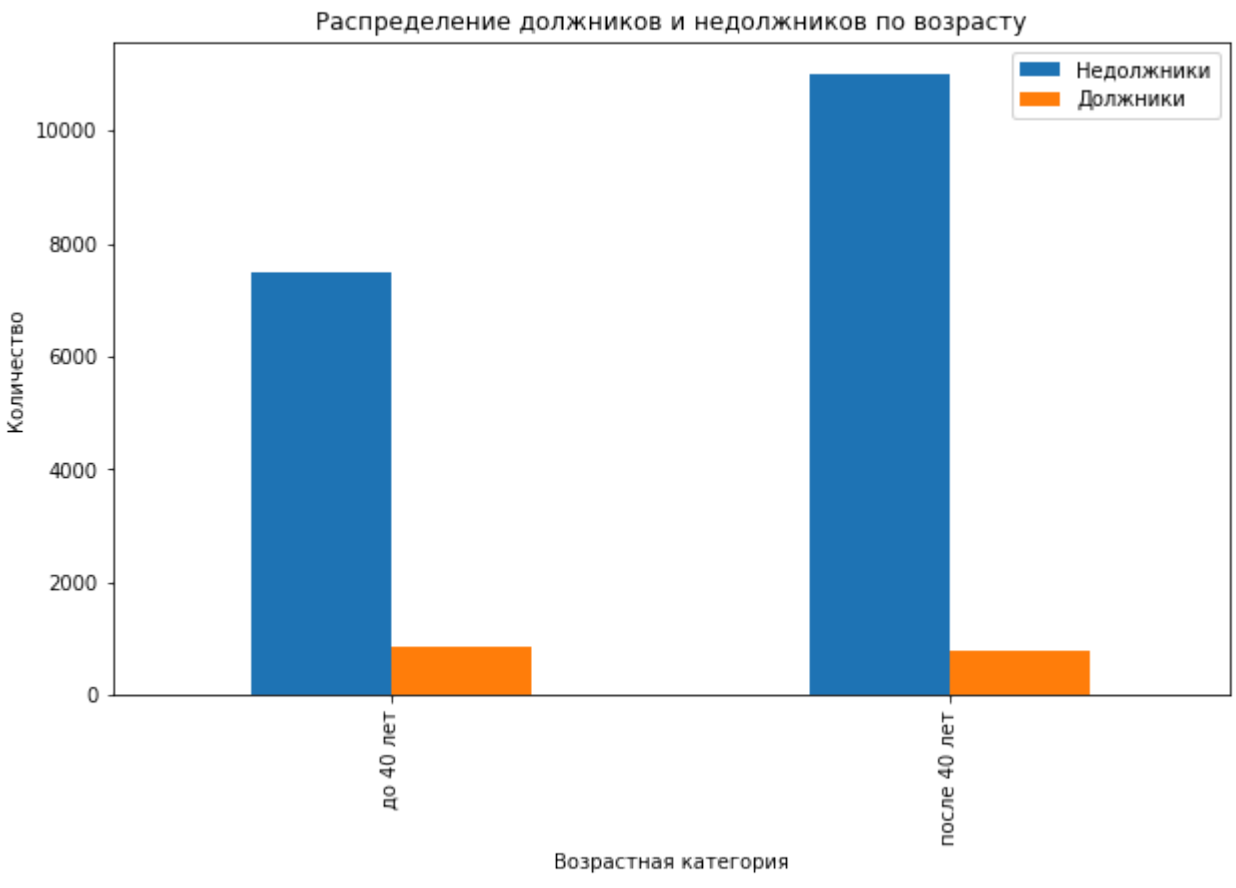

- **Количество детей**

In [163…
```
children_pivot = df.pivot_table(index='childrens_category', columns='debt', values='children', aggfunc='count')
display(children_pivot)
children_pivot.plot(kind='bar', figsize=(10, 6))
plt.title('Распределение должников и недолжников по количеству детей')
plt.xlabel('Категория по количеству детей')
plt.ylabel('Количество')
plt.legend(['Недолжники', 'Должники'])
```

debt	0	1
childrens_category		
без детей	12335	1011
от одного до двух	5856	608
от трёх и больше	321	30

Out[163… <matplotlib.legend.Legend at 0x7fbabe9fb850>

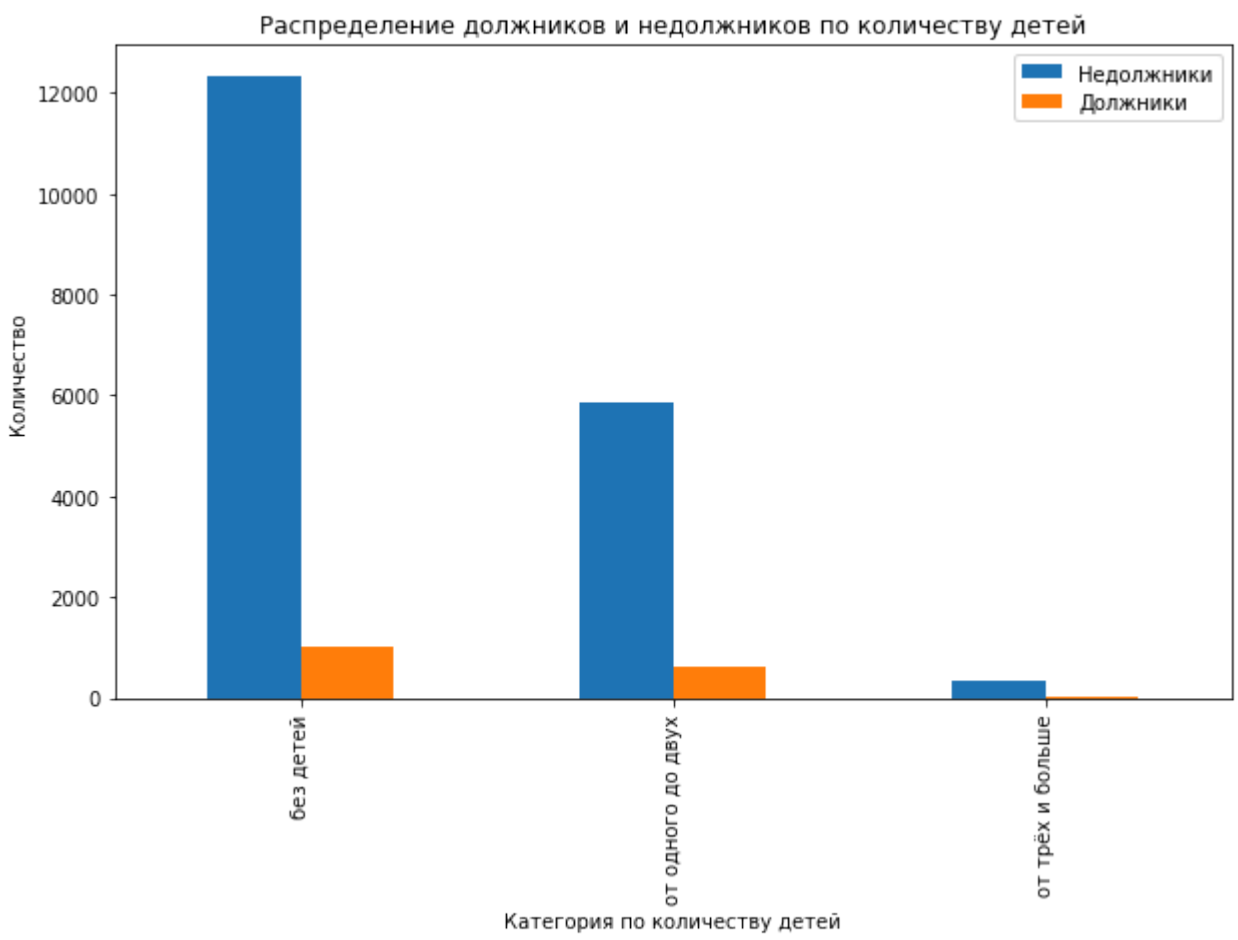

Проверьте исследовательскую гипотезу: у клиентов с детьми более высокий уровень финансовой ответственности и, следовательно, более низкий риск просрочек по кредиту.

1. Сравним количество должников и недолжников в зависимости от количества детей.
2. Построим график для сравнения

In [164…
```
# Место для вашего кода
children_debt_pivot = df.pivot_table(index='childrens_category', columns='debt', values='children', aggfunc='count', fill_value=0)
children_debt_pivot
```

Out[164…

debt	0	1
childrens_category		
без детей	12335	1011
от одного до двух	5856	608
от трёх и больше	321	30

In [165…
```
# Вычислим долю должников в каждой категории
children_debt_pivot['debt_ratio'] = children_debt_pivot[1] / (children_debt_pivot[0] + children_debt_pivot[1])
children_debt_pivot
```

Out[165…

debt	0	1	debt_ratio
childrens_category			
без детей	12335	1011	0.075753
от одного до двух	5856	608	0.094059
от трёх и больше	321	30	0.085470

In [166…
```
# Вычислим долю должников в каждой категории
children_debt_pivot['debt_ratio'] = children_debt_pivot[1] / (children_debt_pivot[0] + children_debt_pivot[1])
```

In [167…
```
children_debt_pivot[['debt_ratio']].plot(kind='bar', figsize=(5, 3), color='skyblue')
plt.title('Доля должников по категориям количества детей')
plt.xlabel('Категория по количеству детей')
plt.ylabel('Доля должников')
```

Out[167… Text(0, 0.5, 'Доля должников')

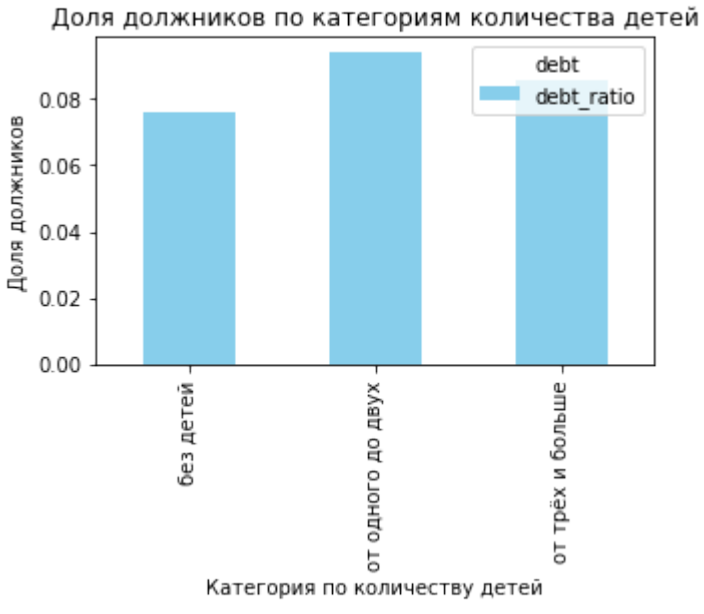

Проверьте исследовательскую гипотезу: одинокие мужчины с низким доходом чаще оказываются должниками, чем семейные мужчины со средним доходом.

1. Нужно создать 2 группы
   - Одинокие мужчины с низким доходом.
   - Семейные мужчины со средним доходом.
2. Построить сводные таблицы
3. Построить графики визуализрующие итог

- выведем только те столбцы, что будем анализировать

In [168…
```
display(df[['gender','family_status', 'income_category','debt']].head(10))
```

	gender	family_status	income_category	debt
0	F	married	Высокий доход	0
1	F	married	Низкий доход	0
2	M	married	Средний доход	0
3	M	married	Высокий доход	0
4	F	civil partnership	Средний доход	0
5	M	civil partnership	Высокий доход	0
6	F	married	Высокий доход	0
7	M	married	Средний доход	0
8	F	civil partnership	Низкий доход	0
9	M	married	Средний доход	0

- проверим уникальные значения для столбцов gender и family_status

In [169…
```
df['gender'].unique()
```

Out[169…
```
array(['F', 'M', 'Unknown'], dtype=object)
```

In [170…
```
df['family_status'].unique()
```

Out[170…
```
array(['married', 'civil partnership', 'widow / widower', 'divorced',
       'unmarried'], dtype=object)
```

- видно, что есть такой вариант как 'civil partnership', но в условии не оговоренно что считать сименйм мужчиной
- поэтому будем рассматривать только вариант 'married'

In [171…
```
# Группы
single_low_income_men = df[(df['gender'] == 'M') & (df['family_status'] == 'unmarried') & (df['income_category'] == 'Низкий доход')]
display(single_low_income_men.head(10))
```

	children	days_employed	dob_years	education	education_id	family_status	family_status_id	gender	income_type	debt	total_income	purpose
479	0	-3029.321191	29	secondary education	1	unmarried	4	M	employee	0	17784.268	housing
834	0	-1523.564571	29	bachelor's degree	0	unmarried	4	M	employee	0	14129.326	purchase of the house
1085	0	-1618.549219	29	secondary education	1	unmarried	4	M	civil servant	0	16564.878	housing transactions
1277	0	-1205.259599	20	secondary education	1	unmarried	4	M	employee	0	14782.012	housing
1281	1	-318.559894	43	secondary education	1	unmarried	4	M	business	0	17122.443	housing renovation
1286	0	-5020.574409	35	secondary education	1	unmarried	4	M	employee	0	14321.866	real estate transactions
1344	0	-1418.055816	24	secondary education	1	unmarried	4	M	employee	1	17464.201	buying my own car
1430	0	-340.644655	27	secondary education	1	unmarried	4	M	employee	0	18332.241	building a property
1741	0	-405.802043	25	secondary education	1	unmarried	4	M	business	0	18242.696	buying my own car
1847	2	-679.171126	35	secondary education	1	unmarried	4	M	employee	0	16890.247	housing

In [172…

```
married_medium_income_men = df[(df['gender'] == 'M') & (df['family_status'] == 'married') & (df['income_category'] =='Средний доход' )]
display(married_medium_income_men.head(10))
```

	children	days_employed	dob_years	education	education_id	family_status	family_status_id	gender	income_type	debt	total_income	purpose	i
2	0	-5623.422610	33	secondary education	1	married	0	M	employee	0	23341.752	purchase of the house	
7	0	-152.779569	50	secondary education	1	married	0	M	employee	0	21731.829	education	
9	0	-2188.756445	41	secondary education	1	married	0	M	employee	0	23108.150	purchase of the house for my family	
26	0	0.000000	41	secondary education	1	married	0	M	civil servant	0	23202.870	education	
60	1	-2534.462390	48	secondary education	1	married	0	M	employee	0	20784.365	to become educated	
66	0	-916.428829	28	secondary education	1	married	0	M	employee	0	23234.324	to become educated	
72	1	0.000000	32	bachelor's degree	0	married	0	M	civil servant	0	23202.870	transactions with commercial real estate	
76	1	-2252.192722	44	bachelor's degree	0	married	0	M	employee	0	23838.725	buying a second-hand car	
78	0	359722.945074	61	bachelor's degree	0	married	0	M	retiree	0	28020.423	purchase of a car	
83	0	0.000000	52	secondary education	1	married	0	M	employee	0	23202.870	housing	

In [173…

```
# Подсчет должников в каждой группе
single_low_income_men_debt_ratio = single_low_income_men['debt'].mean()
married_medium_income_men_debt_ratio = married_medium_income_men['debt'].mean()
print(f'Доля должников среди одиноких мужчин с низким доходом: {single_low_income_men_debt_ratio}')
print(f'Доля должников среди семейных мужчин со средним доходом: {married_medium_income_men_debt_ratio}')
```

```
Доля должников среди одиноких мужчин с низким доходом: 0.16939890710382513
Доля должников среди семейных мужчин со средним доходом: 0.09852717115286948
```

In [174…

```
# Сводные таблицы
single_low_income_men_pivot = single_low_income_men.pivot_table(index='family_status', columns='debt', values='total_income', aggfunc='coun
married_medium_income_men_pivot = married_medium_income_men.pivot_table(index='family_status', columns='debt', values='total_income', aggfu

display(single_low_income_men_pivot)
print('')
display(married_medium_income_men_pivot)
```

debt	0	1
family_status		
unmarried	152	31

debt	0	1
family_status		
married	1775	194

In [175…
```
import matplotlib.pyplot as plt

# Визуализация
labels = ['Одинокие мужчины с низким доходом', 'Семейные мужчины со средним доходом']
debt_ratios = [single_low_income_men_debt_ratio, married_medium_income_men_debt_ratio]

plt.figure(figsize=(10, 6))
plt.bar(labels, debt_ratios, color=['red', 'green'])
plt.title('Доля должников среди различных групп клиентов')
plt.xlabel('Группы клиентов')
plt.ylabel('Доля должников')
```

Out[175…
```
Text(0, 0.5, 'Доля должников')
```

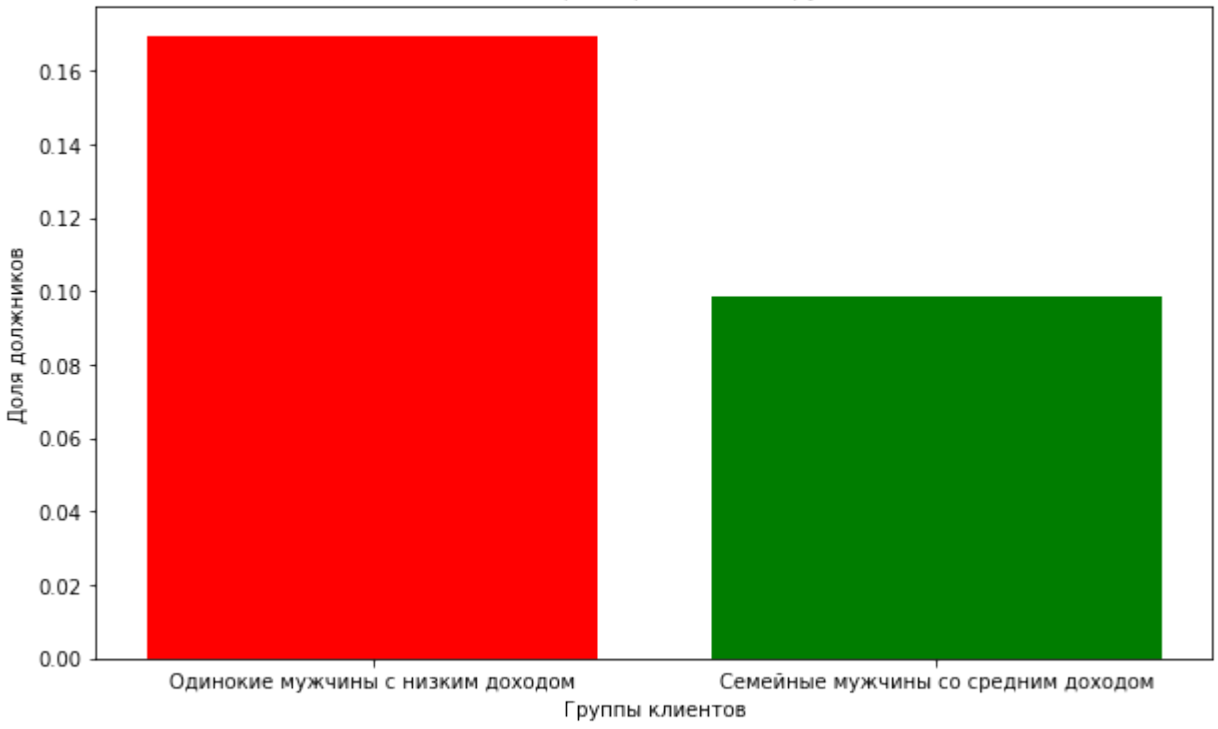

Шаг 6. Напишите общий вывод

- На основе построенных графиков в шаге 5 можно сделать следующие выводы
  - Уровень дохода
    - с увеличением дохода количество должников в основном снижается
    - наибольшее количество дллжников наблюдается среди людей снизким и очень низкми доходом
    - **то есть уровень дохода один из главных рисков возникнвоения задолжности**
  - Образование
    - основные должники срели людей со средним образованием
    - **чем выше уровень образования, тем меньше вероятность быть должником**
  - Возраст
    - в обоих категориях с одной стороны основнвая масса людей без задоллжности, сдругой строны количество должников сопоставимо
    - однако после 40 недолжников существенно больше, что может быть связано с опытом и ростом финансовой грамотности
  - Количество детей
    - среди клиентов без детей самое большое количество как должников, так и недолжников
    - с деьтми от 3 и выше количество должников существенно падает
    - возможно наличие детей не позволяет быть более финансово рискованным

Распределение между должниками и недолжниками действительно отличается в зависимости от уровня дохода, образования, возраста и количества детей.

- Низкий доход и среднее образование увеличиают вероятность задолженности
- Высшее образование и высокий уровень дохода плюс возраст от 40 снижают риск стать должником.

Вывод по гипотезе 1

- таблица и визуализация не подтверждают гипотезу о том, что клиенты с детьми имеют более высокий уровень финансовой ответственности.

Вывод по гипотезе 2

- Гипотеза о том, что одинокие мужчины с низким доходом чаще оказываются должниками, чем семейные мужчины со средним доходом, подтверждается

- **Одинокие мужчины с низким доходом имеют более высокую вероятность просрочить кредиту по сравнению с семейными мужчинами со средним доходом.**

Таким образом первая гипотеза не подтверждается, вторая гпитеза подтвреждается

*Шаг 7. Проведите дополнительное исследование

(Необязательное задание) Исследуйте причины оформления кредита. Правда ли, что люди, которые брали кредит на образование, реже всего оказывались должниками?

In [176…
```
# Изучите уникальные значения в поле purpose
unique_purposes = df['purpose'].unique()
print('Уникальные значения в поле purpose:', unique_purposes)
```

```
Уникальные значения в поле purpose: ['purchase of the house' 'car purchase' 'supplementary education'
 'to have a wedding' 'housing transactions' 'education' 'having a wedding'
 'purchase of the house for my family' 'buy real estate'
 'buy commercial real estate' 'buy residential real estate'
 'construction of own property' 'property' 'building a property'
 'buying a second-hand car' 'buying my own car'
 'transactions with commercial real estate' 'building a real estate'
 'housing' 'transactions with my real estate' 'cars'
 'second-hand car purchase' 'getting an education' 'to become educated'
 'car' 'wedding ceremony' 'to get a supplementary education'
 'purchase of my own house' 'real estate transactions' 'to own a car'
 'purchase of a car' 'profile education' 'university education'
 'buying property for renting out' 'to buy a car' 'housing renovation'
 'going to university' 'getting higher education']
```

делим клиентов на группы по образованию и остальным причинам

In [177…
```
# Функция для разделения на группы по цели кредита
def find_education_purpose(purpose):
    if 'education' in purpose.lower():
        return 'education'
    else:
        return 'other'


df['purpose_category'] = df['purpose'].apply(find_education_purpose)
```

In [178…
```
purpose_debt_pivot = df.pivot_table(index='purpose_category', columns='debt', values='purpose', aggfunc='count', fill_value=0)


purpose_debt_pivot['debt_ratio'] = purpose_debt_pivot[1] / (purpose_debt_pivot[0] + purpose_debt_pivot[1])
display(purpose_debt_pivot)


purpose_debt_pivot[['debt_ratio']].plot(kind='bar', figsize=(10, 6), color='red')
plt.title('Доля должников по категориям целей кредита')
plt.xlabel('Цель кредита')
plt.ylabel('Доля должников')
plt.show()
```

debt	0	1	debt_ratio
purpose_category			
education	2644	275	0.094210
other	15868	1374	0.079689

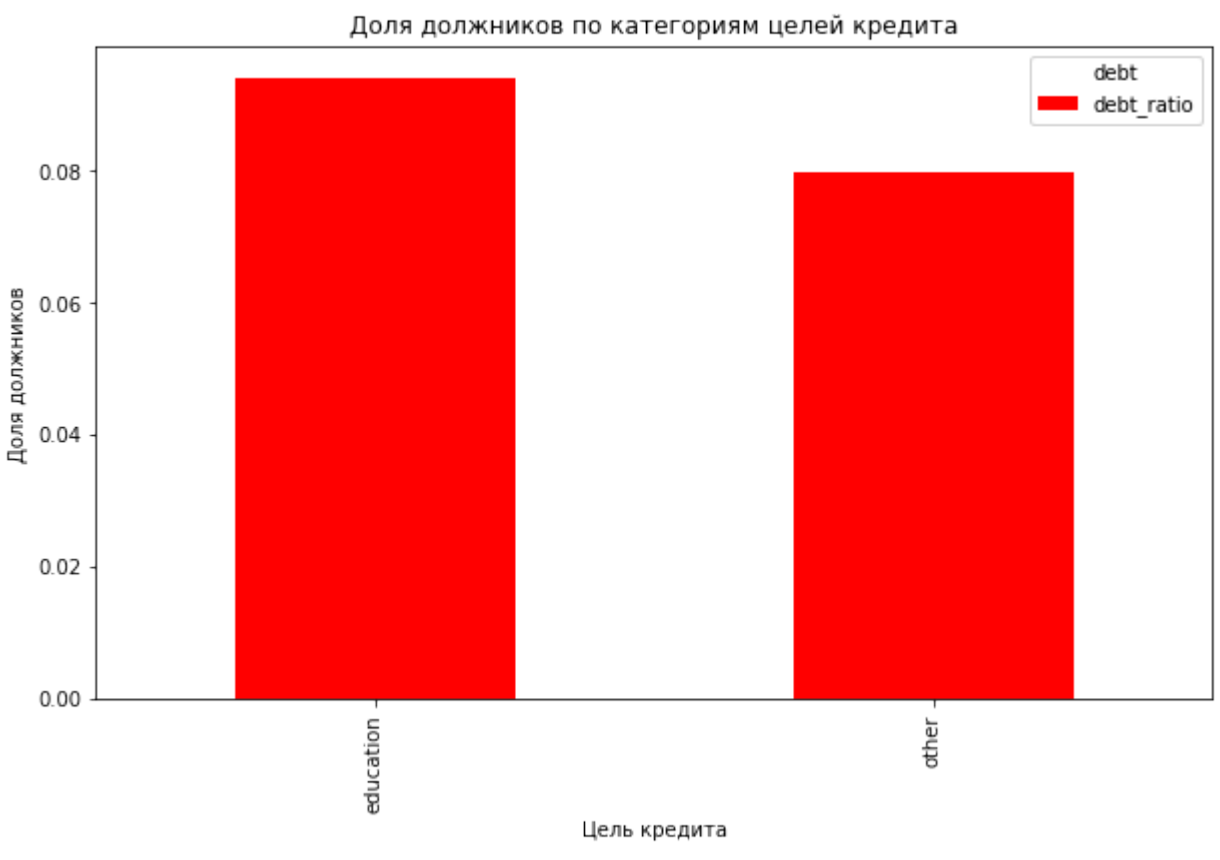

таким образом должников среди людей, бравших кредит на оьразование выше, чем по остальным причинам

- гпиотеза не подтвержена